

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



PROYECTO DE INTELIGENCIA DE NEGOCIOS

"Sistema BI para la Optimización del Abastecimiento y Disponibilidad de RES (Alineado a la AEI.03.01 - CENARES)"

ASIGNATURA

Inteligencia de Negocios

DOCENTE

Alarcon Loayza, Luis Alberto

GRUPO 05

- Astorga Agüero, Rosa Arlet
- Barrantes Cabello, Gabriel Fernando
- Gutierrez Machacuay, Frank Jeison
- Huarcaya Pariona, Mario Anderson
- Llamocca Milla, Piero Josue
- Prudencio Vargas, Ricardo Nicolas
- Velarde Saucedo, Khalep Nahuel

Lima, Perú

2026

ÍNDICE

1. Identificación del Proyecto	3
1.1. Nombre del proyecto	3
1.2. Organización seleccionada	3
1.3. Área interna beneficiada	3
1.4. Naturaleza del negocio	3
2. Objetivos del Proyecto	4
2.1. Objetivo General	4
2.2. Beneficios estratégicos esperados	4
3. Naturaleza del Problema a Superar	5
3.1. Descripción del problema actual	5
3.2. Impacto en la toma de decisiones	6
4. Requerimientos del Proyecto	8
4.1. Requerimientos del Negocio	8
4.2. Requerimientos del Sistema de Inteligencia de Negocios (BI)	9
4.3. Matriz de Trazabilidad de Requerimientos	10
4.4. Requerimientos de Rendimiento y Calidad de Datos (No Funcionales)	10
5. Alcance del Sistema BI	11
5.1. Entregables incluidos	11
5.2. Exclusiones del proyecto	12
6. Plan General de Actividades (Metodología Ralph Kimball)	12
6.1. Identificación de los procesos de negocio	12
6.2. Definición de la granularidad de los datos	13
6.3. Identificación de Dimensiones y Tabla de Hechos (Enfoque Kimball y Bus Matrix)	14
7. Cronograma de Trabajo	19
7.1. Historias de Usuario (HU)	22
7.2. Product Backlog General	25
7.3. Organización por Sprints	29
8. Planificación Técnica y Operativa	30
8.1. Recursos y herramientas a utilizar (ETL, BD, Visualización, IA)	30
8.2. Arquitectura del Pipeline de Datos Desacoplado	31
8.3. Preparación de los ambientes de desarrollo	32
9. Equipo de Trabajo	33
9.1. Roles de los miembros del equipo SCRUM	33
9.2. Protocolo de seguimiento y control de avance semanal	34
10. Referencias bibliográfica	34

1. Identificación del Proyecto

1.1. Nombre del proyecto

Sistema BI para la Optimización del Abastecimiento y Disponibilidad de RES (Alineado a la AEI.03.01 - CENARES).

1.2. Organización seleccionada


Centro Nacional de Abastecimiento de Recursos Estratégicos en Salud (CENARES), entidad ejecutora dependiente del Ministerio de Salud (MINSA).

1.3. Área interna beneficiada

Dirección de Almacén y Distribución (DAD) y la Dirección de Programación de CENARES, las cuales son responsables directas del control logístico, los despachos (PECOSAS) y el aseguramiento de la cadena de frío a nivel nacional.

1.4. Naturaleza del negocio

Gestión pública y logística integral del abastecimiento de recursos estratégicos en salud (RES) para el Estado peruano. Su operación se orienta al cumplimiento de las Acciones Estratégicas Institucionales (AEI) del Ministerio de Salud, orientando sus actividades operativas a garantizar la disponibilidad oportuna de insumos. El núcleo crítico es asegurar que esta disponibilidad alcance las metas institucionales (85%), especialmente en productos termosensibles que requieren una logística especializada para evitar rupturas de cadena de frío y pérdidas económicas por merma.



Fuente: RM N°491-2024/MINSA. Aprueba el Manual de Operaciones de CENARES



2. Objetivos del Proyecto

2.1. Objetivo General

Diseñar e implementar un Sistema de Inteligencia de Negocios (BI) para la **Optimización del Abastecimiento y Disponibilidad de RES**, alineado a la **AEI.03.01** del Plan Operativo de CENARES. El sistema permitirá analizar la eficiencia logística y predecir riesgos críticos en la cadena de frío como primer módulo de alto impacto, transformando los datos de las PECOSAS en información estratégica para elevar los niveles de disponibilidad del 39% actual hacia la meta institucional del 85%.

2.2. Beneficios estratégicos esperados

- **Cumplimiento de Metas Gubernamentales (AEI 03.01):** El BI proporciona la base analítica necesaria para que CENARES logre el incremento proyectado en la disponibilidad de medicamentos esenciales hacia el 2028, alineando la ejecución operativa con la planificación multianual del pliego.
- **Reducción de Mermas y Pérdidas Económicas:** Al identificar los cuellos de botella y las rutas con mayor incidencia de retrasos, CENARES podrá tomar acciones correctivas para evitar que los lotes de vacunas superen su tiempo máximo de exposición fuera de las cámaras frigoríficas. Esto no solo ahorrará millones de soles al Estado, sino que asegurará que el presupuesto público invertido en RES se traduzca en disponibilidad efectiva para el ciudadano, evitando pérdidas por fallas logísticas.
- **Visibilidad Integral de la Cadena Logística:** Pasar de un registro fragmentado en archivos planos (CSV y Excel) a un Data Mart centralizado, permitiendo a los directivos monitorear en tiempo real el volumen despachado, los tiempos de tránsito y el estado térmico de la carga a nivel nacional.
- **Toma de Decisiones Proactiva mediante IA:** La integración de un modelo predictivo (Machine Learning) permitirá a la institución anticiparse a los problemas, identificando matemáticamente qué destinos, meses o proveedores de transporte representan un alto riesgo de retraso logístico crítico. De este modo, el sistema permitirá a la institución anticiparse a interrupciones en el flujo de abastecimiento y garantizar la entrega de lotes críticos en zonas periféricas.
- **Evaluación y Fiscalización Basada en Datos:** Capacidad para auditar el desempeño de los almacenes ("REFRIG" vs. "NO REFRIG") y la eficiencia de los proveedores logísticos tercerizados basándose en métricas exactas (KPIs) de cumplimiento de tiempos de entrega.

3. Naturaleza del Problema a Superar

3.1. Descripción del problema actual

Según el Plan Operativo Institucional (POI) Multianual 2026-2028, CENARES enfrenta un desafío estructural crítico: la disponibilidad nacional de Recursos Estratégicos en Salud (RES) se encuentra actualmente en un nivel del 39%. Para cumplir con la Acción Estratégica Institucional (AEI.03.01) exigida por el Estado, la institución tiene la meta imperativa de elevar esta disponibilidad al 85%. Para alcanzar este objetivo, es indispensable optimizar el flujo de abastecimiento, prestando especial atención a los bienes de mayor valor e impacto sanitario.

CENARES gestiona un volumen crítico superior a 66,000 registros anuales de operaciones logísticas, de los cuales aproximadamente 7,000 corresponden a productos termosensibles (vacunas, insulina y otros medicamentos refrigerados) que requieren mantenerse en un rango estricto de temperatura de 2°C a 8°C durante toda la cadena de distribución. La naturaleza geográfica del Perú, con su diversidad territorial que abarca costa, sierra y selva, junto con distancias que pueden superar las 36 horas de tránsito para llegar a zonas rurales de frontera, convierte la logística de cadena de frío en un desafío operativo de alta complejidad.

Actualmente, la institución opera con un sistema de información fragmentado que presenta las siguientes limitaciones críticas:

- **Calidad deficiente de los datos fuente:** Los archivos CSV generados por el sistema transaccional de CENARES contienen inconsistencias estructurales significativas, tales como columnas con valores nulos, celdas mezclando texto y números sin formato homogéneo, y ausencia de un campo unificador que identifique explícitamente si un lote requiere refrigeración. Aproximadamente 60,000 registros carecen de información en el campo “Tipo de Almacén”, siendo imposible distinguir mediante consultas directas qué envíos corresponden a medicamentos refrigerados y cuáles a carga seca.
- **Falta de trazabilidad integral del proceso logístico:** La información se encuentra atomizada en dos fuentes desconectadas (PECOSAS de despacho y reportes de distribución), sin una estructura relacional que permita cruzar automáticamente las fechas de salida del almacén, los tiempos de tránsito, los destinos finales y los proveedores de transporte. Esto impide calcular con exactitud cuánto tiempo ha transcurrido un lote de vacunas fuera de condiciones controladas de refrigeración.
- **Ausencia de capacidad analítica y predictiva:** El personal directivo de la Dirección de Almacén y Distribución (DAD) carece de herramientas de visualización de datos (dashboards) que permitan monitorear en tiempo cercano al real los indicadores clave de desempeño (KPIs) logísticos, tales como volumen despachado vs. entregado, identificación de cuellos de botella por región, o comparación del rendimiento entre distintos operadores logísticos tercerizados. Más crítico aún, no existe ningún modelo matemático que permita anticipar qué combinaciones de variables (destino geográfico,

época del año, proveedor de transporte, tipo de vehículo) representan un riesgo elevado de falla térmica antes de que el lote salga del almacén central.

- **Toma de decisiones reactiva en lugar de proactiva:** Los funcionarios responsables de autorizar despachos actualmente operan bajo un modelo de reacción ante problemas consumados. Solo cuando un hospital periférico reporta la recepción de vacunas en mal estado (excursión térmica visible mediante indicadores químicos en las cajas) se inicia un proceso manual de auditoría retroactiva de la ruta logística. Este modelo genera pérdidas económicas significativas y pone en riesgo la salud pública al retrasar programas de inmunización en zonas de alta vulnerabilidad epidemiológica.

La combinación de estos factores resulta en una tasa de desperdicio (Wastage Rate) que afecta tanto la eficiencia presupuestaria del MINSA como el cumplimiento de la **meta del 85% de disponibilidad (AEI.03.01)**, particularmente en zonas donde el acceso a servicios de salud ya es limitado por razones geográficas y socioeconómicas.

3.2. Impacto en la toma de decisiones

Las limitaciones descritas en el apartado anterior se traducen en un impacto tangible y crítico en tres niveles decisionales dentro de la estructura orgánica de CENARES y del MINSA:

3.2.1. Nivel Operativo (Dirección de Almacén y Distribución - DAD)

El personal técnico que debe autorizar cada despacho (PECOSA) carece de visibilidad inmediata sobre variables críticas que determinan el éxito o fracaso de un envío refrigerado. Preguntas básicas como “¿Cuántos despachos a la región de Ucayali han experimentado demoras en los últimos tres meses?”, “¿Qué proveedor logístico tiene la mejor tasa de entregas dentro del plazo para la sierra central?” o “¿Qué destinos tienen mayor probabilidad de superar el umbral de 36 horas de tránsito?” no pueden responderse sin un proceso manual y laborioso de consolidación de múltiples archivos Excel.

Esta limitación obliga a los funcionarios a tomar decisiones basadas en criterios subjetivos (experiencia personal, intuición, o reglas empíricas heredadas de gestiones anteriores) en lugar de criterios objetivos fundamentados en el análisis histórico de patrones logísticos. El resultado es una asignación ineficiente de recursos: lotes críticos de vacunas son enviados por rutas que históricamente han presentado incidentes térmicos, mientras que se sobredimensiona la infraestructura de refrigeración para rutas que estadísticamente no la requieren.

3.2.2. Nivel Táctico (Dirección de Programación de CENARES)

Los responsables de la planificación trimestral y anual de la distribución nacional necesitan identificar patrones estacionales, evaluar el rendimiento comparativo entre distintas Redes Integradas de Salud (IPRESS) y proyectar demandas futuras de capacidad logística. Sin un sistema de Business Intelligence, la Dirección de Programación no puede cuantificar fehacientemente cuáles son los meses del año con mayor riesgo térmico (probablemente los meses de verano en la selva amazónica,

donde las temperaturas ambientales superan los 35°C), ni puede determinar con precisión estadística cuántas horas adicionales de tránsito ocurren en promedio durante la temporada de lluvias en la sierra sur.

Esta ausencia de información consolidada limita severamente la capacidad de planificación estratégica. Las decisiones de inversión en nueva infraestructura de refrigeración portátil, la negociación de contratos con proveedores logísticos tercerizados basada en métricas de desempeño verificables, o la redistribución geográfica de los puntos de almacenamiento intermedio (almacenes avanzados) se realizan sin el respaldo de un análisis cuantitativo robusto, aumentando el riesgo de decisiones que no optimizan los recursos públicos.

3.2.3. Nivel Estratégico (Alta Dirección del MINSA)

Desde una perspectiva de política pública nacional, la Alta Dirección evalúa el éxito de CENARES en función del cumplimiento de la AEI.03.01 (alcanzar el 85% de disponibilidad de RES). La ausencia de métricas confiables sobre la tasa de desperdicio en la cadena de frío no solo impide medir el progreso hacia esta meta, sino que dificulta gravemente la rendición de cuentas ante organismos de control (Contraloría General de la República) y organismos de cooperación internacional (OPS, UNICEF). Un lote de vacunas que se malogra por excursión térmica impacta directamente en el indicador de disponibilidad nacional, representando además una pérdida económica y un costo de oportunidad sanitario inaceptable.

Adicionalmente, la falta de un modelo predictivo basado en Inteligencia Artificial impide al MINSA diseñar políticas preventivas basadas en evidencia. Por ejemplo, si un modelo de Machine Learning determina que los envíos realizados en diciembre y enero hacia provincias de la selva tienen un 40% más de probabilidad de falla térmica en comparación con otros meses, la alta dirección podría tomar decisiones estratégicas tales como reforzar los protocolos de supervisión durante ese periodo crítico, exigir equipos de refrigeración adicionales a los proveedores logísticos, o incluso evaluar la factibilidad de implementar almacenes intermedios en ciudades de la Amazonía para acortar los tiempos de tránsito final.

En síntesis, el problema actual no es únicamente técnico o informático, sino que constituye una barrera estructural para la modernización de la gestión pública sanitaria en el Perú. La implementación del sistema de Business Intelligence propuesto permitirá transformar datos operativos fragmentados en información estratégica accionable, habilitando así una toma de decisiones basada en evidencia cuantitativa en los tres niveles jerárquicos de la organización.

4. Requerimientos del Proyecto

4.1. Requerimientos del Negocio

Se definen las necesidades de la Alta Dirección de CENARES orientadas a la optimización de la cadena de suministro en el marco del POI 2026-2028:

ID	Nombre del Requerimiento	Descripción Estratégica	Meta / Impacto Institucional
RN-01	Monitoreo Estratégico de Disponibilidad de RES	Monitorear de forma centralizada las brechas de desabastecimiento de Recursos Estratégicos en Salud a nivel nacional.	Elevar de forma medible la disponibilidad nacional desde el 39% actual hacia la meta institucional del 85% (Alineado a la AEI.03.01 del POI).
RN-02	Protección Patrimonial y Control de Cadena de Frío	Priorizar el control y la supervisión del transporte de productos termosensibles de alto costo (vacunas y medicamentos oncológicos).	Minimizar las mermas económicas y asegurar la calidad y eficacia sanitaria del insumo médico entregado al ciudadano en regiones críticas.
RN-03	Auditoría y Evaluación de Proveedores Logísticos	Evaluar el desempeño operativo, cumplimiento de plazos y niveles de servicio de los operadores logísticos tercerizados.	Detectar cuellos de botella geográficos por ruta y optimizar la negociación de contratos públicos basados en métricas exactas de rendimiento.
RN-04	Gestión Preventiva de Riesgos de Desabastecimiento	Transicionar de un modelo logístico reactivo ante incidentes consumados a un modelo predictivo y proactivo dentro de la Dirección de Almacén y Distribución (DAD).	Anticipar escenarios de desabastecimiento e interrupciones en el flujo de distribución antes de que la carga salga del almacén central.
RN-05	Gobernanza Analítica y Rendición de Cuentas	Centralizar y unificar los registros históricos que actualmente se encuentran fragmentados en archivos planos aislados.	Proveer una base única de verdad auditable que sustente los reportes institucionales ante la Contraloría General, el MINSA y organismos internacionales (OPS, UNICEF).

4.2. Requerimientos del Sistema de Inteligencia de Negocios (BI)

Los requerimientos del sistema definen las capacidades tecnológicas necesarias (ETL, almacenamiento dimensional, análisis OLAP y analítica predictiva) para dar soporte y satisfacer los objetivos del negocio.

ID	Nombre del Requerimiento	Capacidad Técnica del Sistema	Componente / Stack Relacionado
RS-01	Ingesta Automatizada de Fuentes Heterogéneas	El sistema debe ser capaz de extraer, limpiar y unificar de forma automatizada los volcados periódicos de los datasets de PECOSAS, Distribución CD1 y el Directorio Nacional RENIPRESS	Python + Pentaho Data Integration
RS-02	Arquitectura Desacoplada en Capas (Data Stage)	El sistema debe implementar una <i>Staging Area</i> física intermedia como zona de aterrizaje segura para aislar los procesos de calidad antes de la estructuración del Data Mart analítico.	PostgreSQL (Tabla intermedia independiente)
RS-03	Segmentación e Imputación Lógica de Datos	El sistema debe ejecutar transformaciones de tipo <i>Split Fields</i> para estandarizar categorías logísticas e imputar automáticamente valores nulos para identificar la carga seca de la termosensible.	Pentaho Data Integration (Pasos <i>Split Fields</i> y <i>Filter Rows</i>).
RS-04	Motor de Cálculo Dimensional Semántico	Capacidad para procesar agregaciones complejas y lógicas de negocio, calculando de forma exacta el <i>Lead Time</i> logístico (diferencia temporal entre requerimiento y entrega física).	PostgreSQL / Expresiones DAX en Microsoft Power BI.
RS-05	Módulo de Clasificación Predictiva Avanzada	El sistema debe integrar un algoritmo entrenado de Machine Learning que calcule de forma matemática la probabilidad porcentual de retraso crítico basado en combinaciones históricas (Mes + Ruta + Proveedor).	Python (Librerías Scikit-Learn y Pandas unificadas en el flujo).
RS-06	Interfaz Visual Ejecutiva y Multidimensional	El sistema debe proveer dashboards interactivos de navegación rápida (< 3 segundos) con mapas de calor georreferenciados y alertas visuales cuando el tiempo de tránsito supere las 36 horas críticas.	Microsoft Power BI (Capa analítica final para la toma de decisiones).
RS-07	Motor de Cálculo del Indicador Disponibilidad Institucional	El sistema debe calcular de forma automatizada el porcentaje de disponibilidad nacional de RES, mediante una medida DAX que relacione el volumen de despachos completados/entregados a tiempo contra el volumen total requerido (o programado) en un periodo determinado, permitiendo comparar el resultado frente a la meta institucional del 85% (AEI.03.01) y segmentar el indicador por región, producto y periodo.	PostgreSQL (vista o consulta agregada en el Data Mart) + Expresiones DAX en Microsoft Power BI.

4.3. Matriz de Trazabilidad de Requerimientos

ID RN	Requerimiento del negocio	Stakeholder solicitante	RS vinculados	Capacidad técnica cubierta	HU asociada	Entregable / Sprint	Prioridad	Estado
RN-01	Monitoreo estratégico de disponibilidad de RES Elevar disponibilidad nacional de 39% → 85% (AEI.03.01)	Alta Dirección MINSA	RS-01, RS-02, RS-07, RS-06	Ingesta + Staging + Cálculo del % de disponibilidad + Dashboard ejecutivo	HU-03 HU-04 HU-07	Data Mart PostgreSQL + Dashboard Power BI Sprint 1 y 2	Alta	En progreso
RN-02	Protección patrimonial y control de cadena de frío Minimizar mermas en productos termosensibles (vacunas, oncológicos)	DAD — Dirección de Almacén y Distribución	RS-03 RS-06	Segmentación Split Fields (REFRIGERADO / NO REFRIGERADO) + alertas visuales de umbral térmico en Power BI	HU-02 HU-06	Flujo ETL Pentaho + Vista estacional Power BI Sprint 1 y 2	Alta	En progreso
RN-03	Auditoría y evaluación de proveedores logísticos Medir cumplimiento de plazos y rendimiento de operadores tercerizados por ruta	Dirección de Programación	RS-04 RS-06	Cálculo de Lead Time logístico (fecha despacho – fecha recepción) con semáforo visual de umbral crítico (36 h)	HU-05	KPI Lead Time en Power BI (.pbix) Sprint 2	Alta	Completado
RN-04	Gestión preventiva de riesgos de desabastecimiento Transición de modelo reactivo a modelo predictivo en la DAD antes del despacho	DAD — Dirección de Almacén y Distribución	RS-05 RS-06	Modelo ML (Scikit-learn) que clasifica cada despacho como RIESGO ALTO / BAJO según historial de ruta, proveedor y mes	HU-08 HU-09 HU-10	Script Python .ipynb + alerta integrada en Power BI Sprint 3	Alta	Pendiente

RN-05	Gobernanza analítica y rendición de cuentas Base única de verdad auditable para Contraloría, MINSA, OPS y UNICEF	Alta Dirección MINSA	RS-02 RS-06	Staging Area con trazabilidad origen-destino + reporte gerencial exportable con KPIs auditables	HU-01 HU-07	Tabla stg_despachos PostgreSQL + Reporte exportable Power BI Sprint 1 y 2	Media	En progreso
-------	--	--------------------------------------	-------------	--	---------------------------	--	-----------------------	-----------------------------

4.4. Requerimientos de Rendimiento y Calidad de Datos (No Funcionales)

Para garantizar la viabilidad, escalabilidad y la robustez del sistema OLAP ante la Alta Dirección, la infraestructura tecnológica deberá satisfacer los siguientes parámetros:

- **Soporte de Gran Volumen de Datos:** El sistema y la arquitectura de almacenamiento en PostgreSQL deberán soportar y procesar eficientemente cargas históricas iniciales e incrementales que **superen los 100,000 registros consolidados**, derivados de la unificación de las tres fuentes de datos (PECOSAS, CD1 y el Directorio Nacional de IPRESS de SUSALUD).
- **Eficiencia en Tiempos de Respuesta:** Las consultas ejecutadas desde la capa de visualización de Power BI hacia el Data Mart deben procesarse bajo una arquitectura de procesamiento analítico rápido, garantizando que el refresco de los indicadores y la carga de los mapas geográficos tomen menos de 3 segundos bajo demanda.
- **Garantía y Validación de Calidad (Data Quality):** El proceso ETL desarrollado en Pentaho deberá implementar reglas estrictas de validación de calidad antes de la carga física en el Data Mart. Esto incluye el rechazo o redirección de registros con inconsistencias críticas en campos unificadores, la homogeneización de formatos de fecha a estándar internacional (YYYY-MM-DD) y la conversión de cadenas de texto a mayúsculas limpias sin caracteres especiales para asegurar una integridad referencial absoluta.

5. Alcance del Sistema BI

El alcance del presente proyecto se delimita al desarrollo del **primer módulo analítico de alto impacto (enfocado en la Cadena de Frío)**, el cual servirá como base para monitorear y optimizar la disponibilidad de Recursos Estratégicos en Salud (RES) en cumplimiento de la **AEI.03.01**. Para ello, se realizará la ingesta, procesamiento, análisis y visualización de los datos logísticos históricos proporcionados por los portales de Datos Abiertos del Estado Peruano (datasets de **PECOSAS** y **Distribución de medicamentos**), enriquecidos dimensionalmente con el **Directorio Nacional de Instituciones Prestadoras de Servicios de Salud (IPRESS)** para el mapeo geográfico de los destinos.

5.1. Entregables incluidos

Para cumplir con los objetivos estratégicos propuestos, el proyecto culminará con la entrega funcional de los siguientes componentes:

- **Proceso de Integración de Datos (ETL):** Flujos automatizados desarrollados en Pentaho Data Integration (PDI) para la extracción, limpieza, transformación (estandarización de formatos, manejo de nulos) e integración de las tres fuentes oficiales de CENARES e IPRESS.

- **Data Mart Estructurado:** Diseño e implementación de un repositorio analítico relacional en PostgreSQL bajo la metodología de Kimball (esquema estrella), que contendrá las tablas de hechos de los despachos logísticos y las dimensiones asociadas (Tiempo, Geografía, Tipo de Producto, Proveedor Logístico).
- **Capa de Visualización de Alto Nivel:** Dashboards interactivos desarrollados en Microsoft Power BI orientados a la toma de decisiones. Estos reportes incluirán KPIs estratégicos como el nivel de cumplimiento para la meta de disponibilidad del 85%, volúmenes de despacho, tiempos de tránsito (Lead Time) y mapeo de cuellos de botella geográficos que generan mermas térmicas.
- **Modelo de Analítica Predictiva:** Un script de Machine Learning implementado en Python (utilizando librerías como Pandas y Scikit-learn) que analizará el historial del Data Mart para predecir la probabilidad de retrasos críticos. Este modelo protegerá la cadena de frío, mitigando el riesgo operativo y las pérdidas patrimoniales que impiden al Estado alcanzar sus metas de abastecimiento.
- **Documentación Técnica:** Entrega del código fuente organizado (scripts SQL de creación, archivos .ktr/.kjb de Pentaho, archivo .pbix de Power BI y Notebooks .ipynb de Python).

5.2. Exclusiones del proyecto

Para garantizar la viabilidad del desarrollo dentro de los **04 Sprints planificados bajo el enfoque híbrido SCRUM (del Sprint 0 al Sprint 3)**, el proyecto excluye explícitamente lo siguiente:

- **Desarrollo de Hardware o IoT en Tiempo Real:** El proyecto no contempla la adquisición, instalación ni integración en tiempo real de sensores físicos de temperatura (dataloggers) o telemetría GPS en la flota de transporte. Se trabajará exclusivamente con los reportes tabulares de los datasets mencionados.
- **Actualizaciones en Tiempo Real (Streaming Data):** Las cargas de datos desde las fuentes hacia el Data Mart se realizarán de manera periódica (arquitectura por lotes o batch processing) y no mediante un flujo continuo o streaming en tiempo real.
- **Sistemas Transaccionales (OLTP):** No se desarrollará ninguna aplicación web, de escritorio o móvil para el ingreso, modificación o eliminación de nuevos registros operativos logísticos en CENARES. El sistema será estrictamente analítico (OLAP).
- **Análisis de Módulos Financieros o Compras:** Quedan fuera del alcance del modelo dimensional las áreas de licitaciones públicas, compras, contabilidad, presupuestos y recursos humanos del MINSA o CENARES. El enfoque es 100% operativo y logístico.

6. Plan General de Actividades (Metodología Ralph Kimball)

6.1. Identificación de los procesos de negocio

En el contexto del sistema de Inteligencia de Negocios aplicado a la optimización del abastecimiento y disponibilidad de RES en CENARES, se realiza la identificación de los procesos de negocio clave. Según la metodología de Ralph Kimball, este paso es fundamental para comprender las operaciones que impactan directamente en las metas institucionales y definir correctamente la estructura del modelo dimensional.

En este caso, se han identificado dos procesos principales que intervienen en la logística de distribución de productos médicos:

Proceso	Descripción	Dataset asociado
Despacho de almacén (PECOSA)	Corresponde al registro de salida de productos desde los almacenes del sistema. Incluye información sobre proveedor, fecha de despacho y tipo de almacén (refrigerado o no refrigerado).	DATASET_PECOSA 2023
Distribución logística	Representa el traslado de los productos desde los almacenes hacia los destinos finales, como hospitales o redes de salud. Incluye información sobre destino, cantidad enviada, tipo de producto y estado logístico.	CSV Dataset_CD1
Enriquecimiento Geográfico	Datos de ubicación de redes de salud	Directorio IPRESS (RENIPRESS)

La identificación de estos procesos permite analizar de manera integral la cadena logística, considerando tanto el origen de los productos como su distribución. Esto es esencial para evaluar riesgos en la cadena de frío (nuestro primer módulo de alto impacto) y detectar ineficiencias operativas que **impiden a la institución alcanzar la meta del 85% de disponibilidad (AEI.03.01)**.

6.2. Definición de la granularidad de los datos

La granularidad define el nivel de detalle con el que se almacenan los datos dentro del modelo dimensional. Una correcta definición de la granularidad es clave para asegurar la consistencia y utilidad del análisis posterior.

En el presente proyecto, se establece la siguiente granularidad:

“Cada registro representa un envío individual de un producto específico, en una fecha determinada, desde un almacén hacia un destino, incluyendo sus condiciones logísticas.”

Cada registro contiene información relevante que permite analizar de forma detallada cada operación logística, incluyendo:

- Fecha de envío o despacho
- Producto (ítem)
- Cantidad enviada
- Destino (hospital o red de salud)
- Tipo de producto (refrigerado o no refrigerado)
- Estado logístico del envío

Esta definición de granularidad permite realizar análisis específicos sobre cada transacción, facilitando la identificación de cuellos de botella, demoras en la distribución y riesgos asociados a la pérdida de la cadena de frío, los cuales representan mermas críticas que afectan directamente la disponibilidad nacional de medicamentos.

6.3. Identificación de Dimensiones y Tabla de Hechos (Enfoque Kimball y Bus Matrix)

Acatando la metodología de Ralph Kimball, el diseño de nuestro Data Mart no se deriva simplemente de las fuentes de datos operativas (CSVs), sino que nace estrictamente para dar respuesta a los Requerimientos del Negocio (RN) definidos en el Sprint 0.

Para garantizar una arquitectura escalable y evitar "islas de información", hemos construido la **Matriz de Procesos Dimensionales (Bus Matrix)**. Esta matriz vincula nuestros procesos logísticos críticos (identificados en los requerimientos) con las dimensiones conformadas que les darán contexto analítico.

Matriz de Procesos Dimensionales (Bus Matrix) - CENARES

Cada fila representa un proceso crítico del negocio derivado de nuestros requerimientos estratégicos (RN), y cada columna representa una dimensión conformada que le dará contexto analítico a las métricas. Esta matriz asegura una arquitectura escalable y evita la creación de silos de información aislados.

Procesos de Negocio (Filas) \ Dimensiones (Columnas)	Tiempo	Producto (Termosensible)	Ubicación (IPRESS)	Proveedor Logístico	Almacén	Estrategia (Programa)
1. Monitoreo de Disponibilidad de RES (RN-01)	X	X	X		X	X
2. Control de Cadena de Frío (RN-02)	X	X	X		X	
3. Evaluación de Desempeño de Proveedores Logísticos	X		X	X		
4. Predicción de Riesgo de Retrasos (RN-04)	X	X	X	X	X	
5. Gobernanza y Rendición de Cuentas (RN -05)	X	X	X	X	X	X

Nota de Trazabilidad: Los procesos de negocio descritos se mapearon de forma estricta según las necesidades del negocio (RN-01 a RN-05). Toda la información elemental para construir estas dimensiones ya fue extraída, limpiada y unificada de forma exitosa durante el Sprint 1 dentro de nuestro ambiente de Data Stage.

Justificación del Modelo de Datos:

Como se evidencia en la Bus Matrix, las dimensiones han sido seleccionadas estratégicamente. La dimensión **Ubicación** es transversal a todos los procesos, lo que nos permite mapear los cuellos de botella desde cualquier perspectiva. Por otro lado, la dimensión **Proveedor** nace directamente de la necesidad del RN-03 para evaluar la eficiencia de terceros. La tabla de hechos central, **Hechos_Logistica**, almacenará la granularidad de cada despacho (CANTIDAD) y las llaves degeneradas (NROPECOSA). Este diseño híbrido nos asegura que el modelo soporte tanto la visualización OLAP en Power BI como la ingesta de datos para nuestro algoritmo predictivo en Python.

Tabla de Hechos: Hechos_Logistica

La tabla de hechos almacena las métricas cuantitativas del proceso logístico, permitiendo evaluar el desempeño de la distribución y detectar posibles riesgos.

Métrica	Descripción
Cantidad despachada	Representa el volumen físico (ítems) de medicamentos distribuidos en cada envío. (Métrica aditiva).
Tiempo de tránsito (Lead Time)	Número de días/horas transcurridos entre el despacho de CENARES y la recepción en el destino final. (Métrica semi-aditiva).
Probabilidad de Riesgo	Valor porcentual derivado del modelo de Machine Learning que estima la probabilidad de que el envío sufra retrasos críticos.

Nota: La tabla de hechos Hechos_Logistica integra, además de estas métricas, las llaves degeneradas (NROPECOSA, NROCD) para auditoría y las llaves foráneas (Foreign Keys - FK) que conectan con las 6 dimensiones del modelo. Esto garantiza la integridad referencial y permite el cruce de datos (slicing and dicing) en Power BI.

Dimensiones del modelo

Las dimensiones proporcionan el contexto descriptivo necesario para analizar las métricas de la tabla de hechos desde múltiples perspectivas:

Dimensión	Descripción
Dim_Tiempo	Permite analizar la estacionalidad de los envíos mediante atributos como Fecha, Mes, Trimestre y Año.
Dim_Producto	Identifica unívocamente el medicamento despachado mediante sus códigos oficiales (CODIGOSIGA, CODIGOSISMED) y su descripción descriptiva (ITEM).
Dim_Ubicacion (Destino)	Representa la jerarquía geográfica de la red de salud receptora (IPRESS, Departamento, Provincia, Distrito).
Dim_Proveedor	Permite filtrar y evaluar el desempeño operativo de los operadores logísticos tercerizados encargados del transporte.
Dim_Almacen (Condición)	Segmenta estrictamente los despachos según su requerimiento térmico ("Refrigerado" para cadena de frío vs. "Carga Seca").
Dim_Estrategia	Agrupar los envíos según el programa presupuestal de salud pública al que pertenecen y su meta financiera (CODMEF).

Modelo dimensional (Esquema Estrella de 6 puntas)

El modelo propuesto se ha diseñado bajo una estructura arquitectónica tipo Estrella (Metodología Kimball). En el núcleo de esta arquitectura se ubica la tabla de hechos Hechos_Logistica, la cual almacena la granularidad transaccional de los despachos y contiene las llaves foráneas (FK) que la conectan con seis dimensiones conformadas descentralizadas: Dim_Tiempo, Dim_Producto, Dim_Ubicacion, Dim_Proveedor, Dim_Almacen y Dim_Estrategia.

Este diseño desnormalizado minimiza la cantidad de cruces relacionales (JOINS) en la base de datos, garantizando una alta velocidad de respuesta (rendimiento OLAP) al procesar y agregar volúmenes masivos de datos históricos. Asimismo, el modelo expone de manera explícita los atributos, llaves primarias (PK) y métricas necesarias para asegurar la integridad referencial en PostgreSQL.




Figura 1: Diseño del Modelo Dimensional Lógico (Objetivo del Sprint 2). Para evitar arquitecturas monolíticas y asegurar el desacoplamiento de datos, este modelo estrella se poblará físicamente en el paso de transformación del Sprint 2, tomando como única fuente de verdad la data limpia persistida en el Data Stage.

Aplicación y Justificación del Modelo

La implementación de este esquema dimensional no es un mero reflejo de las fuentes de origen, sino una respuesta directa a los Requerimientos del Negocio (RN) definidos estratégicamente. La inclusión de la dimensión Dim_Proveedor, por ejemplo, es el componente estructural que permitirá a CENARES auditar el rendimiento de terceros logísticos (RN-03), mientras que Dim_Almacen aísla los atributos de la cadena de frío para priorizar productos termosensibles (RN-02).

En la capa de explotación de datos, este modelo relacional centralizado cumplirá un doble propósito:

- 1. Analítica Descriptiva (BI):** Alimentará directamente a Microsoft Power BI, facilitando la creación de medidas DAX complejas y dashboards interactivos para que la Alta Dirección pueda segmentar el abastecimiento (slicing and dicing) por ubicación geográfica, estacionalidad o tipo de medicamento.
- 2. Analítica Predictiva (IA):** Servirá como un *dataset* estructurado y limpio para el entrenamiento del algoritmo de Machine Learning en Python. Al estar los datos consolidados en la tabla de hechos, el modelo predictivo podrá cruzar variables históricas (tiempos de tránsito, rutas de la IPRESS, proveedores) para identificar matemáticamente los patrones de retraso y calcular la probabilidad de ruptura térmica en futuros despachos.

En conjunto, esta arquitectura transforma datos aislados en un activo estratégico, otorgando a CENARES el soporte tecnológico necesario para transicionar de un enfoque reactivo a uno predictivo, alineando de manera medible sus operaciones logísticas con la meta de disponibilidad del 85% exigida en el POI Multianual 2026-2028 (AEI.03.01).

7. Cronograma de Trabajo

Para la ejecución del proyecto de Inteligencia de Negocios enfocado en la gestión logística de CENARES y su alineación con la meta AEI.03.01 del POI 2026-2028, el equipo ha adoptado un **enfoque híbrido** que combina el marco de trabajo ágil **SCRUM** con la metodología de modelado dimensional **Ralph Kimball**. Este enfoque iterativo e incremental permite adaptar el desarrollo a medida que se profundiza en el análisis de los datos operativos y se construyen progresivamente las capas del sistema BI. El ciclo de desarrollo se gestiona a través de la herramienta **Jira Software**, garantizando la trazabilidad de cada entregable por Sprint.

El proyecto se estructura en **cuatro Sprints numerados del 0 al 3**, cada uno con una duración de dos semanas, donde el Sprint 0 cumple el rol de planificación y arquitectura base del sistema.

Resumen del Cronograma General por Semanas

A continuación se presenta el cronograma general del proyecto organizado por semanas, mostrando la correspondencia entre cada Sprint, sus actividades principales y los entregables comprometidos:

Semana	Sprint	Actividades principales	Entregable comprometido
1 – 2	Sprint 0: Planificación y Arquitectura	Levantamiento de requerimientos, redacción de HU, construcción del Product Backlog priorizado, diseño del modelo dimensional (esquema estrella) y configuración del tablero Jira	Informe del Plan General del Proyecto (este documento) + PPT de presentación
3 – 4	Sprint 1: Ingeniería de Datos	Extracción y perfilamiento de las 3 fuentes CSV, desarrollo de flujos ETL en Pentaho (Split Fields, imputación de nulos, estandarización), implementación y carga del Data Mart en PostgreSQL	Flujos ETL (.ktr/.kjb) + Data Mart poblado y validado en PostgreSQL
5 – 6	Sprint 2: Capa Analítica	Desarrollo de dashboards interactivos en Power BI conectados al Data Mart, construcción de KPIs logísticos (Lead Time, % carga refrigerada, mapa geográfico), reporte exportable para rendición de cuentas	Módulo de Monitoreo de Disponibilidad y Nivel de Servicio: Capacidad analítica gerencial para evaluar brechas y Lead Times de proveedores.
7 – 8	Sprint 3: Analítica Predictiva y Despliegue	Preparación del dataset de entrenamiento (feature engineering), entrenamiento y evaluación del modelo de clasificación de riesgo en Scikit-learn, integración del indicador RIESGO ALTO/BAJO en Power BI, presentación ejecutiva final	Módulo de Gestión Logística Preventiva: Capacidad predictiva integrada para la anticipación de rupturas en la cadena de frío y mitigación proactiva de mermas patrimoniales.

Diagrama de Gantt

Tarea / Entregable			Sprint 0 Planificación y Arquitectura					Sprint 1 Ingeniería de Datos (ETL)					Sprint 2 Capa Analítica (Power BI)					Sprint 3 Analítica Predictiva y Despliegue																								
Semana →			Sem 1					Sem 2					Sem 3					Sem 4					Sem 5					Sem 6					Sem 7					Sem 8				
ID Sprint Descripción de la tarea			J	V	L	M	X	J	V	L	M	X	J	V	L	M	X	J	V	L	M	X	J	V	L	M	X	J	V	L	M	X	J	V	L	M	X					
HU-00a	sprint 0	Levantamiento requerimientos y Product Backlog	X	X	X	X	X																																			
HU-00b	sprint 0	Diseño arquitectura dimensional (Kimball)				X	X	X	X	X	X	X	X																													
PB-03	sprint 0	Definición stack técnico (Pentaho, PostgreSQL, Power BI, Python)						X	X	X	X	X																														
M0	sprint 0	Entrega: Informe Plan General + PPT											◆																													
PB-04	sprint 1	Extracción y perfilamiento CSV fuente (PECOSA, CD1, IPRESS)												X	X	X	X	X																								
PB-05	sprint 1	Desarrollo flujo Split Fields en Pentaho													X	X	X	X																								
PB-06	sprint 1	Imputación nulos y Join con directorio IPRESS														X	X	X																								
PB-07	sprint 1	Implementación Data Mart en PostgreSQL (tablas y dimensiones)														X	X	X	X	X																						
PB-08	sprint 1	Pruebas de integridad referencial y validación ETL															X	X																								
M1	sprint 1	Entrega: Flujos ETL + Data Mart validado en PostgreSQL																	◆																							
PB-09	sprint 2	Dashboard volumen despachos con mapa geográfico																	X	X	X	X	X																			
PB-10	sprint 2	KPI Lead Time con alerta visual (umbral 36 horas)																		X	X	X																				
PB-11	sprint 2	Vista análisis estacional de despachos refrigerados																																								
PB-12	sprint 2	Reporte exportable KPIs para rendición de cuentas																																								
M2	sprint 2	Entrega: Archivo .pbix Dashboards + Informe de avance																											◆													
PB-13	sprint 3	Feature engineering dataset de entrenamiento ML																																								
PB-14	sprint 3	Entrenamiento y evaluación modelo Scikit-learn (precisión ≥75%)																																								
PB-15	sprint 3	Integración alertas RIESGO ALTO/BAJO en Power BI																																								
PB-16	sprint 3	Auditoría final: precisión modelo y calidad dashboards																																								
PB-17	sprint 3	Documentación técnica y presentación ejecutiva final																																								
M3	sprint 3	Entrega Final: Sistema BI Integrado + Notebook ML + Presentación																																			◆					
LEYENDA																																										
	Sprint 0: Planificación y Arquitectura																																									
	Sprint 1: Ingeniería de Datos (ETL)																																									
	Sprint 2: Capa Analítica (Power BI)																																									
	Sprint 3: Analítica Predictiva y Despliegue																																									
	◆ Hito / Entrega																																									

7.1. Historias de Usuario (HU)

Las Historias de Usuario representan los requerimientos funcionales del sistema desde la perspectiva de los interesados reales del proyecto. Se han identificado cuatro roles de usuario: el **Directivo de la DAD** (nivel operativo), el **Director de Programación** (nivel táctico), la **Alta Dirección del MINSA** (nivel estratégico) y el **Analista de Datos del equipo BI** (usuario técnico). Las historias se agrupan en **cuatro épicas funcionales**, correspondiendo la primera (Épica 0) al Sprint 0 de planificación y arquitectura, y las tres restantes a los sprints de desarrollo técnico (Sprints 1, 2 y 3).

Épica	ID	Título	Historia de Usuario	Criterios de aceptación	Prioridad	Sprint
E0 — Planificación y Arquitectura	HU-00a	Levantamiento de requerimientos y definición del Product Backlog	Como Scrum Master del equipo BI, quiero documentar formalmente todos los requerimientos del negocio en HU con criterios de aceptación y organizarlos en un Product Backlog priorizado, para contar con una base de trabajo validada antes de iniciar el desarrollo técnico.	• Se documentan al menos 10 HU con título, descripción y criterios. • El backlog está priorizado por valor de negocio y dependencia técnica. • El backlog es gestionado en el tablero Jira.	Muy Alta	Sprint 0
E0 — Planificación y Arquitectura	HU-00b	Diseño de la arquitectura dimensional del Data Mart (Kimball)	Como Database Architect del equipo BI, quiero diseñar el modelo estrella Kimball antes de crear cualquier tabla en PostgreSQL, para asegurar que la estructura soporte los dashboards de Power BI y el modelo predictivo de ML.	• El modelo estrella documenta Hechos_Logistica y sus 6 dimensiones. • Se especifican métricas y atributos principales de cada dimensión. • El diagrama está aprobado por el Product Owner antes del Sprint 1.	Muy Alta	Sprint 0
E1 — Calidad y Disponibilidad de Datos	HU-01	Unificación de fuentes de datos CSV	Como Analista de Datos del equipo BI, quiero extraer y unificar automáticamente los datasets PECOSA 2023, Dataset_CD1 y RENIPRESS 2026 desde los archivos CSV, para contar con una fuente de datos consolidada y libre de duplicados como insumo del Data Mart.	• Los datasets se integran en un único flujo ETL en Pentaho. • No existen registros duplicados por clave de despacho. • El proceso es reproducible y documentado.	Muy Alta	Sprint 1

E1 — Calidad y Disponibilidad de Datos	HU-02	Segmentación automática de productos refrigerados (Split Fields)	Como Analista de Datos del equipo BI, quiero que el sistema identifique y separe automáticamente los productos refrigerados de los de carga seca mediante Split Fields, para segmentar correctamente los análisis de cadena de frío sin intervención manual.	• La columna "Tipo de Almacén" queda en "REFRIGERADO" o "NO REFRIGERADO". • Los ~60,000 registros sin valor reciben la imputación "NO REFRIGERADO". • El flujo valida el resultado con un conteo por categoría.	Alta	Sprint 1
E1 — Calidad y Disponibilidad de Datos	HU-03	Estandarización de formatos y calidad de datos	Como Analista de Datos del equipo BI, quiero que el sistema estandarice todos los formatos de fecha, texto y valores numéricos, para garantizar la integridad referencial al cargar los datos en el Data Mart PostgreSQL.	• Todas las fechas siguen el formato YYYY-MM-DD. • Los campos de texto están normalizados en mayúsculas sin caracteres especiales. • Cero errores de tipo de dato al cargar a PostgreSQL.	Alta	Sprint 1
E2 — Monitoreo y Visualización Logística	HU-04	Dashboard de volumen de despachos por región	Como Directivo de la DAD, quiero visualizar en un dashboard el volumen de despachos por región y tipo de producto, para monitorear el flujo de abastecimiento y evitar cuellos de botella que pongan en riesgo la meta del 85% (AEI.03.01).	• Muestra un mapa geográfico del Perú con volumen por región. • Existen filtros por fecha, tipo de producto y proveedor. • Los datos se refrescan desde PostgreSQL automáticamente.	Alta	Sprint 2
E2 — Monitoreo y Visualización Logística	HU-05	Monitoreo de Lead Time por ruta y proveedor	Como Directivo de la DAD, quiero ver el tiempo promedio de tránsito (Lead Time) por ruta y proveedor logístico, para identificar cuellos de botella y tomar decisiones correctivas antes de autorizar nuevos despachos críticos.	• El KPI "Tiempo Promedio de Tránsito" es visible y segmentable. • Las rutas que superan las 36 horas se resaltan visualmente. • El cálculo es consistente con las fechas del Data Mart.	Alta	Sprint 2
E2 — Monitoreo y Visualización Logística	HU-06	Análisis estacional de despachos refrigerados	Como Director de Programación de CENARES, quiero analizar el comportamiento estacional de los despachos refrigerados por mes y región, para planificar la capacidad logística en periodos de mayor riesgo térmico.	• Incluye vista de tendencia mensual y trimestral. • Permite comparar rendimiento entre distintas IPRESS. • Los filtros aíslan únicamente productos de cadena de frío.	Media	Sprint 2

E2 — Monitoreo y Visualización Logística	HU-07	Reporte exportable de KPIs para rendición de cuentas	Como Alta Dirección del MINSA, quiero acceder a métricas consolidadas de KPIs exportables, para sustentar la rendición de cuentas sobre la AEI.03.01 ante la Contraloría y organismos internacionales (OPS, UNICEF).	• Existe un reporte exportable con KPIs principales (% carga refrigerada, Wastage Rate, % entregas a tiempo). • Los datos son trazables hasta el registro fuente del Data Mart.	Media	Sprint 2
E3 — Predicción de Riesgo en Cadena de Frío	HU-08	Clasificación automática de riesgo por despacho refrigerado	Como Directivo de la DAD, quiero que el sistema clasifique automáticamente cada despacho refrigerado como riesgo alto o bajo antes de ser autorizado, para anticiparme a rupturas de cadena de frío y tomar medidas preventivas oportunas.	• El modelo ML clasifica con precisión mínima del 75%. • Variables de entrada: destino, proveedor, mes y tiempo estimado. • El resultado (RIESGO ALTO/BAJO) es visible en Power BI.	Alta	Sprint 3
E3 — Predicción de Riesgo en Cadena de Frío	HU-09	Identificación de variables críticas de riesgo logístico	Como Data Scientist del equipo BI, quiero identificar las variables más influyentes en la predicción de demoras críticas, para documentar los factores de riesgo y dar recomendaciones concretas a la DAD.	• El modelo genera un ranking de importancia de variables (feature importance). • Se documentan al menos 3 factores de riesgo relevantes. • Los resultados están incluidos en el informe técnico final.	Alta	Sprint 3
E3 — Predicción de Riesgo en Cadena de Frío	HU-10	Estimación de probabilidad de retraso crítico por combinación de variables.	Como Alta Dirección del MINSA, quiero que el sistema estime la probabilidad de falla térmica para combinaciones críticas de variables (destino + mes + proveedor), para diseñar políticas preventivas basadas en evidencia cuantitativa.	• Permite consultar riesgo para combinaciones específicas de variables. • Los resultados se expresan como probabilidad porcentual. • El modelo está entrenado con datos históricos reales de CENARES 2023.	Alta	Sprint 3

7.2. Product Backlog General

El Product Backlog constituye el inventario completo y priorizado de todos los requerimientos del Sistema BI de CENARES. Se organiza en dos niveles complementarios: el **Product Backlog de Historias de Usuario**, que resume los requerimientos desde la perspectiva de los interesados con su estimación de esfuerzo, y el **Product Backlog de Ítems Técnicos**, que desglosa las tareas concretas de implementación derivadas de cada HU. Cada ítem de la segunda tabla es trazable hasta su Historia de Usuario de origen.

7.2.1. Product Backlog de Historias de Usuario

ID	Nombre de la Historia	Prioridad	SP	Épica	Sprint	Estado	RS	RN
HU-00a	Levantamiento de requerimientos y Product Backlog	Muy Alta	3	E0 — Planificación y Arquitectura	Sprint 0	Completo	01	01
HU-00b	Diseño de arquitectura dimensional (Kimball)	Muy Alta	5		Sprint 0	Completo	03	01
HU-01	Unificación de fuentes de datos CSV	Muy Alta	3	E1 — Calidad y Disponibilidad de Datos	Sprint 1	Completo	01	05
HU-02	Segmentación automática de productos refrigerados (Split Fields)	Alta	5		Sprint 1	Completo	03	02
HU-03	Estandarización de formatos y calidad de datos	Alta	3		Sprint 1	Completo	02	01
HU-04	Dashboard de volumen de despachos por región	Alta	8	E2 — Monitoreo y Visualización Logística	Sprint 2	Pendiente	06	01
HU-05	Monitoreo de Lead Time por ruta y proveedor	Alta	5		Sprint 2	Pendiente	04	03
HU-06	Análisis estacional de despachos refrigerados	Media	5		Sprint 2	Pendiente	06	02
HU-07	Reporte exportable de KPIs para rendición de cuentas	Media	3		Sprint 2	Pendiente	06	05
HU-08	Clasificación automática de probabilidad de retraso crítico por despacho	Alta	13	E3 — Predicción de Riesgo de Desabastecimiento y Retrasos	Sprint 3	Pendiente	05	04
HU-09	Identificación de variables predictivas para el riesgo de desabastecimiento	Alta	8		Sprint 3	Pendiente	05	04
HU-10	Estimación de probabilidad de retraso logístico por combinación de variables (Ruta/Més/Proveedor)	Media	8		Sprint 3	Pendiente	05	04

Total de Story Points por Sprint:

Sprint	Story Points
Sprint 0	8
Sprint 1	11
Sprint 2	21
Sprint 3	29
Total	69

7.2.2. Product Backlog de Ítems Técnicos

Los siguientes ítems representan las tareas concretas de implementación derivadas de las Historias de Usuario. Cada ítem está asociado a su HU de origen y al Sprint en que será ejecutado.

ID	Nombre del ítem	HU asociada	Rol Responsable	Prioridad	Sprint	Tipo de Requerimiento
PB-01	Definición formal de HU, roles y criterios de aceptación	HU-00a	Product Owner	Muy Alta	Sprint 0	Requerimiento del Sistema (RS)
PB-02	Diseño del modelo dimensional (esquema estrella Kimball)	HU-00b	Data Architect			
PB-03	Definición de arquitectura técnica del stack (Pentaho, PostgreSQL, Power BI, Python)	HU-00a, HU-00b	Scrum Master			
PB-04	Extracción y perfilamiento de los archivos CSV fuente (PECOSA 2023, Dataset_CD1 e IPRESS)	HU-01	Data Engineer	Alta	Sprint 1	Requerimiento del Sistema (RS)
PB-05	Desarrollo del flujo de separación de cadenas Split Fields en Pentaho	HU-02				
PB-06	Imputación de valores nulos y cruce geográfico (Join) con el directorio IPRESS.	HU-02, HU-03				
PB-07	Implementación física del Data Mart en PostgreSQL (tablas de hechos y dimensiones)	HU-01, HU-03				
PB-08	Pruebas de integridad referencial y validación del flujo ETL completo hacia el Data Mart.	HU-01, HU-03	QA de Datos			
PB-09	Dashboard de volumen de despachos con mapa geográfico por región y nivel de red de salud.	HU-04	BI Developer	Media	Sprint 2	Requerimiento del Negocio (RN)
PB-10	KPI de Lead Time por ruta y proveedor con alerta visual de umbral crítico (36 horas).	HU-05	BI Developer			
PB-11	Vista de análisis estacional de despachos para proyectar picos de demanda y desabastecimiento.	HU-06	BI Developer			

PB-12	Reporte exportable de KPIs logísticos para rendición de cuentas (Contraloría, OPS, UNICEF).	HU-07	BI Developer			
PB-13	Preparación del dataset de entrenamiento (selección y feature engineering de variables predictoras).	HU-09	ML Engineer	Media	Sprint 3	Requerimiento del Negocio (RN)
PB-14	Entrenamiento y evaluación del modelo (Scikit-learn) para predecir probabilidad de retraso crítico .	HU-08, HU-10	ML Engineer	Alta		
PB-15	Integración de alertas preventivas de desabastecimiento y "Riesgo Máximo" (cadena de frío) en Power BI.	HU-08	BI Developer	Alta		
PB-16	Auditoría final de precisión matemática del modelo y calidad de datos de los dashboards.	Todas	QA de Datos	Alta		
PB-17	Documentación técnica completa y presentación ejecutiva final del sistema integral.	Todas	Scrum Master	Alta		

Leyenda de prioridades:

- **Muy Alta:** Ítem de planificación o arquitectura base cuya ausencia impide iniciar cualquier desarrollo técnico. Corresponde exclusivamente a los entregables del Sprint 0.
- **Alta:** Ítem bloqueante o de impacto directo en la meta AEI.03.01. Su no ejecución impide avanzar al Sprint siguiente.
- **Media:** Ítem de alto valor para el usuario final pero que no bloquea la arquitectura base del sistema.

7.3. Organización por Sprints

El proyecto se estructura en cuatro Sprints con una duración de dos semanas cada uno, garantizando entregas continuas de valor funcional y siguiendo el enfoque híbrido SCRUM-Kimball definido por el equipo.

Sprint 0 — Planificación y Arquitectura del Sistema (*Semanas 1 y 2*)

Objetivo: Establecer las bases formales del proyecto: levantar los requerimientos desde la perspectiva de los interesados, definir las Historias de Usuario con sus criterios de aceptación, construir el Product Backlog priorizado y diseñar la arquitectura dimensional del Data Mart antes de escribir una sola línea de código.

Items del backlog: PB-01, PB-02, PB-03

Entregables:

- Product Backlog priorizado con 10 HU formales y criterios de aceptación
- Diseño del modelo dimensional en esquema estrella (tabla Hechos_Logistica + dimensiones asociadas)
- Documento de arquitectura técnica del stack tecnológico
- Configuración del tablero Jira con los Sprints y tareas asignadas por rol

Sprint 1 — Ingeniería de Datos: ETL y Data Mart (*Semanas 3 y 4*)

Objetivo: Construir la capa de datos unificada del sistema. Desarrollar los flujos de extracción, limpieza y transformación en Pentaho para procesar las tres fuentes oficiales de datos, e implementar físicamente el Data Mart dimensional en PostgreSQL.

Ítems del backlog: PB-04, PB-05, PB-06, PB-07, PB-08, PB-09.

Entregables:

- Flujos ETL en Pentaho (.ktr/.kjb) con transformaciones de Split Fields e imputación de nulos
- Dataset integrado y estandarizado (>100,000 registros limpios)
- Data Mart desplegado en PostgreSQL con esquema estrella poblado y validado
- Scripts SQL de creación de tablas documentados en el repositorio

Sprint 2 — Capa Analítica: Dashboards en Power BI (*Semanas 5 y 6*)

Objetivo: Proveer la interfaz analítica de toma de decisiones para la Alta Dirección y la DAD. Conectar Power BI al Data Mart de PostgreSQL y construir los dashboards

interactivos con mapas geográficos y medidas DAX para evaluar el estado logístico frente a la meta de disponibilidad del 85%.

Ítems del backlog: PB-10, PB-11, PB-12, PB-13

Entregables:

- Dashboard interactivo en Power BI (.pbix) con mapa geográfico de despachos por región
- KPIs operativos visibles (*Lead Time* de atención, volumen físico por destino y estado de distribución)
- Mapeo geográfico de cuellos de botella mediante integración con RENIPRESS
- Reporte gerencial exportable para rendición de cuentas.

Sprint 3 — Analítica Predictiva y Despliegue Final (Semanas 7 y 8)

Objetivo: Desarrollar e integrar el modelo de Machine Learning en Python para predecir la probabilidad de retrasos logísticos críticos y riesgos de desabastecimiento a nivel nacional, configurando alertas automáticas de "Riesgo Máximo" cuando las demoras proyectadas afecten a productos de la cadena de frío. Finalizar con el despliegue del sistema integrado y la presentación ejecutiva.

Ítems del backlog: PB-14, PB-15, PB-16, PB-17

Entregables:

- Script Python en Jupyter Notebook (.ipynb) con modelo de clasificación entrenado (Scikit-learn), precisión $\geq 75\%$
- Ranking de importancia de variables (feature importance) con los factores críticos de retraso identificados
- Integración del indicador predictivo de riesgo en los dashboards de Power BI
- Documentación técnica y código fuente consolidado en el repositorio (código fuente, scripts SQL, archivos Pentaho, Notebook y .pbix)
- Presentación ejecutiva del sistema integral ante el docente

8. Planificación Técnica y Operativa

8.1. Recursos y herramientas a utilizar (ETL, BD, Visualización, IA)

Para garantizar la viabilidad y escalabilidad del proyecto, se ha definido un *Stack* tecnológico basado en herramientas líderes en la industria de la Inteligencia de Negocios y Ciencia de Datos, abarcando todo el ciclo de vida del dato:

- **Fuentes de Datos (Origen):** Archivos planos (CSV) extraídos de la Plataforma Nacional de Datos Abiertos del Estado Peruano, integrando un

mínimo de tres fuentes oficiales: los reportes de **PECOSAS**, la **Distribución Logística de CENARES**, y el **Directorio Nacional de IPRESS** (utilizado para el enriquecimiento y mapeo geográfico de las redes de salud). En conjunto, estas fuentes superan los 100,000 registros consolidados.


- **Capa de Integración (ETL):** *Pentaho Data Integration (PDI)*. Se utilizará para la extracción de los CSV, la limpieza de datos (estandarización de celdas combinadas, manejo de valores nulos) y la imputación lógica (ej. catalogar campos vacíos de almacén como "Carga Seca / No Refrigerada"). Pentaho será el motor que alimentará la base de datos.
- **Capa de Almacenamiento (Data Warehouse / Data Mart):** *PostgreSQL*. Se implementará un motor de base de datos relacional para alojar el Data Mart. El diseño seguirá la metodología dimensional de Ralph Kimball, estructurando la información en una tabla de hechos (Envíos) y dimensiones clave (Tiempo, Geografía, Destino IPRESS, Producto, Almacén, Proveedor y Estado).
- **Capa de Visualización (OLAP):** *Microsoft Power BI*. Se conectará directamente a PostgreSQL para modelar los tableros de control (Dashboards). Aquí se programarán las medidas DAX necesarias para calcular los KPIs logísticos (Lead Time, volumen de carga crítica, **nivel de cumplimiento de la meta de disponibilidad del 85%**, etc.) y permitir la navegación interactiva de los directivos.
- **Capa de Analítica Predictiva (Machine Learning):** *Python*. A través de entornos de desarrollo como Jupyter Notebook o Google Colab, se utilizarán las librerías Pandas (para manipulación de DataFrames) y Scikit-learn (para el entrenamiento del modelo de clasificación). El modelo consumirá los datos históricos procesados en el Data Mart para predecir la probabilidad de retrasos logísticos críticos (*Lead Time* excedido) en las rutas nacionales, permitiendo a la DAD y a la Alta Dirección anticipar y mitigar escenarios de desabastecimiento de RES. Asimismo, el script automatizará una regla de priorización que gatillará alertas de "Riesgo Máximo" en Power BI si el retraso proyectado afecta a lotes termosensibles, optimizando de manera proactiva las decisiones de distribución y resguardando los recursos del Estado.

8.2. Arquitectura del Pipeline de Datos Desacoplado

El flujo de información implementado por el equipo rompe el esquema monolítico tradicional mediante un proceso desacoplado de tres etapas bien definidas:

- **Capa de Pre-procesamiento Asíncrono (Python):** Los archivos CSV crudos de origen estatal (PECOSAS y CD1) sufren una limpieza inicial automatizada mediante el script `limpiador.py`. Este componente aísla y une los saltos de línea huérfanos (`\n`, `\r`) dentro del campo observaciones, evitando desalineaciones antes de la lectura formal del ETL.

- **Capa de Integración Dinámica (Pentaho PDI):** Recibe los archivos curados y ejecuta la lógica de unificación relacional. En esta etapa se implementa la **Barrera de Calidad (Data Quality)** mediante filtros Regex para apartar fechas corruptas y se realiza el cruce geográfico (*Stream Lookup*) indexado con la base de datos institucional de RENIPRESS.
- **Capa de Persistencia Intermedia (Data Stage / Staging Area):** Los datos limpios se inyectan a través de JDBC mediante inserciones por lotes (*Batch Update*) hacia PostgreSQL. El hito físico entregado en esta fase consta de la tabla plana **stg_despachos**, la cual resguarda los 6,894 registros validados. Esta tabla actúa como nuestro colchón de seguridad e histórico de auditoría.



8.3. Preparación de los ambientes de desarrollo

Dado que el desarrollo será colaborativo, se establecerá el siguiente entorno de trabajo unificado:

- **Repositorio Centralizado:** Se utilizará un servicio de almacenamiento en la nube (ej. Google Drive o GitHub) para centralizar los archivos CSV originales, los scripts SQL de creación de la base de datos, y los archivos de transformación de Pentaho (.ktr y .kjb).
- **Entorno de Base de Datos:** Se levantará una instancia local de PostgreSQL en el equipo del responsable de la base de datos (o alternativamente en un servicio cloud gratuito como Render o Supabase, si la latencia lo permite), a la cual los demás miembros se conectarán para ingestar datos desde Pentaho y leerlos desde Power BI.
- **Control de Versiones:** El archivo .pbix de Power BI y los Notebooks de Python (.ipynb) se versionarán de forma secuencial (ej. CENARES_BI_v1.2) para evitar conflictos de sobrescritura durante el desarrollo en paralelo.

9. Equipo de Trabajo

9.1. Roles de los miembros del equipo SCRUM

Para asegurar una ejecución eficiente del sistema BI de CENARES y alinearnos a los estándares de una consultoría de datos profesional, se ha distribuido la carga técnica y estratégica en siete roles especializados. Esta estructura permite un flujo de trabajo ágil y la ejecución de tareas en paralelo dentro de un mismo Sprint:

1. **Product Owner (PO) - Astorga Agüero, Rosa Arlet:** Define el *qué* del proyecto. Actúa como puente estratégico con el negocio (CENARES). Es responsable de priorizar el Product Backlog, definir los criterios de aceptación de las Historias de Usuario y validar que los KPIs del sistema midan efectivamente el progreso hacia la meta de disponibilidad del 85% (AEI.03.01).
2. **Scrum Master - Huarcaya Pariona, Mario Anderson:** Define el *cuándo* y vela por el proceso. Es el facilitador del equipo, encargado de gestionar el tablero en Jira, vigilar el cumplimiento estricto de los 4 Sprints planificados, eliminar bloqueos operativos y asegurar que el trabajo paralelo de ingeniería y desarrollo no genere conflictos.
3. **Data Architect - Barrantes Cabello, Gabriel Fernando:** Define el *cómo* a nivel de infraestructura. Es el responsable de diseñar el modelo dimensional (Esquema Estrella bajo la metodología de Ralph Kimball) para asegurar que la estructura soporte tanto el análisis OLAP como la predicción de Machine Learning. Administra el despliegue del Data Mart en PostgreSQL.
4. **Data Engineer - Velarde Saucedo, Khalep Nahuel:** Especialista en la capa de integración (ETL). Su labor principal es construir, probar y automatizar los flujos en Pentaho Data Integration (PDI) para extraer, limpiar y cruzar las tres fuentes de datos oficiales (PECOSAS, Distribución logística y el Directorio Nacional IPRESS).
5. **BI Developer - Llamocca Milla, Piero Josue:** Especialista en visualización y fórmulas DAX. Es el encargado de conectar Power BI al Data Mart en PostgreSQL y transformar los datos en dashboards gerenciales interactivos, construyendo las vistas que la Alta Dirección utilizará para monitorear los cuellos de botella geográficos.
6. **Machine Learning Engineer - Prudencio Vargas, Ricardo Nicolas:** Especialista en analítica avanzada. Responsable de preparar los datos históricos (Feature Engineering) y desarrollar el modelo predictivo en Python (Scikit-learn) enfocado en estimar la probabilidad de retrasos logísticos críticos para alertar sobre posibles escenarios de desabastecimiento.
7. **Data Quality Analyst (QA de Datos) - Gutierrez Machacuay, Frank Jeison:** Garante de la fiabilidad e integridad del sistema. Su rol consiste en validar que las métricas mostradas en los dashboards cuadren exactamente

con los archivos CSV de origen y auditar el nivel de precisión matemática del modelo de Machine Learning antes de su integración final.

9.2. Protocolo de seguimiento y control de avance semanal

Para asegurar el cumplimiento del cronograma y mitigar riesgos de retrasos, el equipo utilizará **Atlassian Jira Software** como herramienta principal de gestión **bajo el enfoque híbrido SCRUM planificado**. El protocolo se ejecutará de la siguiente manera:

- **Gestión de Tableros (Jira Board):** Se creará un tablero Kanban/Scrum en Jira donde el *Product Backlog* será desglosado en tareas (issues) asignadas a cada miembro. Cada tarea pasará por los estados "To Do", "In Progress", "Code Review/Testing" y "Done".
- **Sprint Planning y Review:** Reuniones semanales de 45 minutos previo a las sesiones de laboratorio. En estas reuniones se revisará el tablero de Jira, se evaluará el cumplimiento de las tareas del Sprint actual y se asignará la carga de trabajo para la semana entrante.
- **Sincronización Asíncrona (Daily Virtual):** Uso de un canal de comunicación instantánea (WhatsApp) para reportar bloqueos técnicos en tiempo real, permitiendo que el *Scrum Master* reasigne recursos o brinde soporte inmediato.
- **Integración de Entregables:** El responsable de cada componente deberá cambiar el estado de su tarea a "Done" en Jira y subir su avance al repositorio centralizado al menos 48 horas antes de la revisión con el docente, asegurando un margen para la integración general.

10. Referencias bibliográfica

- *Plataforma Nacional de Datos Abiertos.* (s/f-a). Gob.pe.
<https://www.datosabiertos.gob.pe/dataset/seguimiento-de-pecosas-del-centro-nacional-de-abastecimiento-en-recursos-estrat%C3%A9gicos-0>
- *Plataforma Nacional de Datos Abiertos.* (s/f-b). Gob.pe.
<https://www.datosabiertos.gob.pe/dataset/seguimiento-de-distribuci%C3%B3n-de-medicamentos-del-centro-nacional-de-abastecimiento-en-1>
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). John Wiley & Sons. Recuperado de: <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/books/data-warehouse-dw-toolkit/>

- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann. Recuperado de: <https://www.sciencedirect.com/book/9780123814791/data-mining-concepts-and-techniques>
- Schwaber, K., & Sutherland, J. (2020). *La Guía de Scrum: Las reglas del juego*. Scrum.org. Recuperado de: <https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-Spanish-Latin-American.pdf>
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media. Recuperado de: <https://www.oreilly.com/library/view/hands-on-machine-learning/9781492032632/>
- Superintendencia Nacional de Salud (SUSALUD). (2026). *Registro Nacional de Instituciones Prestadoras de Servicios de Salud (RENIPRESS)*. Plataforma Nacional de Datos Abiertos - GOB.PE. Recuperado de: <http://datos.susalud.gob.pe/dataset/registro-nacional-de-ipress-renipress>